

機械学習の実践的ベイズ最適化

アルゴリズム

ジャスパー・スノーク、ヒューゴ・ラロシェル、ライアン・P・アダムス

トロント大学、シャールブルック大学、ハーバード大学

機械学習アルゴリズムでは、モデルのハイパーパラメータ、正則化項、最適化パラメータを慎重に調整することがしばしば必要になります。しかしながら、こうした調整は往々にして「黒魔術」であり、専門家の経験、暗黙の経験則、あるいは時には総当たりの探索を必要とします。より魅力的なのは、与えられた学習アルゴリズムの性能を、手元のタスクに合わせて最適化できる自動的な手法を開発するという考え方です。本研究では、ベイズ最適化の枠組みの中で自動調整問題を考察します。ベイズ最適化では、学習アルゴリズムの汎化性能をガウス過程（GP）のサンプルとしてモデル化します。GPによって誘導される扱いやすい事後分布は、過去の実験で収集された情報を効率的に活用し、次にどのパラメータを試すべきかを最適に選択することを可能にします。本研究では、ガウス過程の事前分布と関連する推論手順が、ベイズ最適化の成否に大きな影響を与える可能性があることを示します。そして、慎重な選択を行うことで、機械学習アルゴリズムの調整において専門家レベルの性能を超える結果が得られることを示すことができます。また、学習実験の変動コスト（期間）を考慮し、複数のコアを活用して並列実験を実行できる新しいアルゴリズムについても説明します。これらの提案アルゴリズムは、従来の自動手順を改良し、潜在ディリクレ配分法、構造化SVM、畳み込みニューラルネットワークなど、多様な最新アルゴリズムにおいて、人間の専門家レベルの最適化に匹敵、あるいは凌駕する性能を発揮できることを示します。

1. はじめに。機械学習アルゴリズムはパラメータフリーであることは稀です。正規化子の特性、生成モデルの超事前分布、勾配ベース最適化のステップサイズなど、学習手順はほぼ常に、汎化性能に大きく影響する一連の高レベルの選択を必要とします。実務家にとって、帰納的バイアスの一般的な枠組みを指定することは、訓練データに対する特定の重み付けを指定するよりもはるかに容易です。その結果、これらの高レベルのパラメータはしばしば厄介なものとなされ、これらの「ノブ」を可能な限り少なくしたアルゴリズムを開発することが望まれます。

この問題に対するもう一つの、より柔軟なアプローチは、高レベルパラメータの最適化を自動化すべき手順と捉えることです。具体的には、このようなチューニングを、汎化性能を反映する未知のブラックボックス関数の最適化と捉え、そのような問題向けに開発されたアルゴリズムを呼び出すことができます。これらの最適化問題は、学習手順の一部としてよく遭遇する低レベル目的関数とは多少異なる性質を持っています。関数評価は、主要な機械学習アルゴリズムを最後まで実行する必要があるため、非常にコストがかかります。関数評価にコストがかかるこのような状況では、最適なパラメータをどこで探すかというより良い選択を行うために計算時間を費やすことが望ましいです。ベイズ最適化 (Mockus et al., 1978) は洗練されたアプローチを提供し、いくつかの難しい最適化ベンチマーク関数において、他の最先端のグローバル最適化アルゴリズムよりも優れた性能を示すことが示されています (Jones, 2001)。連続関数の場合、ベイズ最適化は通常、未知の関数が1つのサンプルからサンプリングされたと仮定して機能します。

ガウス過程 (GP) を拡張し、観測が行われるにつれてこの関数の事後分布を維持します。この場合、これらの観測値は、最適化したいハイパーパラメータの異なる設定における汎化性能の尺度となります。次の実験のハイパーパラメータを選択するには、現在の最良の結果に対する期待改善度 (EI) ([Mockus et al., 1978](#)) またはガウス過程の上限信頼限界 (UCB) ([Srinivas et al., 2010](#)) を最適化することができます。EI と UCB は、多くのマルチモーダルブラックボックス関数のグローバル最適値を見つけるために必要な関数評価回数において効率的であることが示されています ([Srinivas et al., 2010](#); [Bull, 2011](#))。

しかし、機械学習アルゴリズムには、他のブラックボックス最適化問題とは異なる特定の特性があります。まず、各関数の評価には可変の時間を要する場合があります。つまり、10 個の隠れユニットを持つ小さなニューラルネットワークのトレーニングは、1000 個の隠れユニットを持つ大きなネットワークのトレーニングよりも時間がかかりません。期間を考慮しなくても、クラウドコンピューティングの出現により、学習に大容量メモリを必要とするマシンのコストを経済的に定量化することが可能になり、隠れユニットの数が異なる実験の実際のコスト (ドル単位) が変わります。コストの概念を最適化手順に組み込む方法を理解することが望ましいです。次に、機械学習の実験は、多くの場合、複数のコアまたはマシン上で並列に実行されます。私たちは、この並列性を活用してより迅速により良い解に到達できるベイズ最適化手順を構築したいと考えています。

本研究における私たちの最初の貢献は、機械学習アルゴリズムのベイズ最適化におけるグッドプラクティスの特定です。特に、GP カーネルパラメータの完全なベイズ的処理は、ハイパーパラメータの最適化というより標準的な手順 (例えば、[Bergstra et al. \(2011\)](#)) とは対照的に、堅牢な結果を得るために極めて重要であると主張します。

また、カーネル自体の影響を検証し、デフォルトの二乗指数共分散関数の選択が適切かどうかを検証します。二つ目の貢献は、実験におけるコストを考慮した新しいアルゴリズムの説明です。最後に、複数のコアを活用して機械学習実験を並列実行できるアルゴリズムも提案します。

2. ガウス過程事前分布を用いたベイズ最適化。他の種類の最適化と同様に、ベイズ最適化では、 R, D のサブセットとなる関数 $f(x)$ の最小値を求めることに着目します。ベイズ最適化が他の手法と異なるのは、 $f(x)$ の確率モデルを構築し、このモデルを用いて、不確実性を排除しながら X 内の過去の評価から得られるすべての情報を活用し、局所、どこで関数を次に評価するかを決定する点です。ベイズ最適化の基本的な考え方は、 $f(x)$ の勾配やヘッセ近似に単純に頼らないことです。この結果、比較的少ない評価回数で困難な非凸関数の最小値を求めることができる手法が実現します。ただし、次に試すべき点を決定するために、より多くの計算を実行する必要があります。 $f(x)$ の評価にコストがかかる場合 (機械学習アルゴリズムのトレーニングが必要な場合など)、より良い決定を下すために追加の計算を実行することは容易に正当化されます。ベイズ最適化形式論の概要については、例えば [Brochu et al. \(2010\)](#) を参照してください。本節では、第3節で我々の新たな貢献について議論する前に、一般的なベイズ最適化アプローチについて簡単に説明します。

ベイズ最適化を実行する際には、主に 2 つの選択を行う必要があります。

まず、最適化対象となる関数に関する仮定を表現する関数の事前分布を選択する必要があります。このために、柔軟性と扱いやすさからガウス過程事前分布を選択します。次に、獲得関数を選択する必要があります。これは、モデルの事後分布から効用関数を構築するために使用され、次に評価する点を決定するために使用されます。

2.1. ガウス過程。ガウス過程 (GP) は、便利で強力な事前分布である。

ここでは関数 $f: X \rightarrow R$ の形の分布をとる。GP は

任意の N 点の有限集合 $\{x_n \in X\}$ 上

のガウス分布

北

これらの点の n 番目が関数値 $f(x_n)$ とされ、

そしてガウス分布のエlegantな周辺化特性により、次のように計算できる。

閉形式の周辺分布と条件分布。関数上の分布の台と性質は、平均関数 $m: X \rightarrow R$ と正定値関数によって決定される。

共分散関数 $K: X \times X \rightarrow R$ 。共分散関数の影響について議論する。

セクション 3.1. ガウス過程の概要については、[Rasmussen と Williams \(2006\)](#) を参照してください。

2.2. ベイズ最適化のための獲得関数。関数 $f(x)$ は

はガウス過程事前分布から導かれ、観測値は $\{x_n, y_n\}$ の形式をとる。

北
 $n=1,$

ここで $y_n \sim N(f(x_n), v)$ であり、 v は関数の観測に導入されたノイズの分散である。この事前分布とこれらのデータは関数の事後分布を誘導する。獲得関数は、

これを $a: X \rightarrow R$ と表記すると、 X のどの点を次に評価するかを決定する。

代理最適化 $x_{\text{next}} = \arg \max_x a(x)$ において、いくつかの異なる関数が提案されている。一般に、これらの獲得関数は、過去の観測値だけでなく、

GP ハイパーパラメータ。この依存性を $a(x; \{x_n, y_n\}, \theta)$ と表記する。

獲得関数の一般的な選択肢。ガウス過程事前分布の下では、これらの関数は

モデルに依存するのは、予測平均関数 $\mu(x; \{x_n, y_n\}, \theta)$ と事前2

予測分散関数 σ

$(x; \{x_n, y_n\}, \theta)$ 。以下では、最良の現在の

$x_{\text{best}} = \arg \min_x f(x)$ の値を $\Phi(\cdot)$ とすると、累積分布関数は次の式で表される。

標準正規分布、 $\phi(\cdot)$ は標準正規分布の密度関数を表します。

改善の確率。直感的な戦略の一つは、現在の最良の値よりも改善する確率を最大化すること ([Kushner, 1964](#)) である。GP では、これは次のように計算できる。

分析的に

$$(1) \quad a_{\text{PI}}(x; \{x_n, y_n\}, \theta) = \Phi(\gamma(x)) \quad \gamma(x) = \frac{f(x_{\text{best}}) - \mu(x; \{x_n, y_n\}, \theta)}{\sigma(x; \{x_n, y_n\}, \theta)}.$$

期待される改善。あるいは、現在の最良値に対する期待される改善度 (EI) を最大化することを選択することもできます。これもガウス過程の下で閉じた形を持ちます。

$$(2) \quad a_{\text{EI}}(x; \{x_n, y_n\}, \theta) = \sigma(x; \{x_n, y_n\}, \theta) (\gamma(x) \Phi(\gamma(x)) + N(\gamma(x); 0, 1))$$

GP 信頼度上限境界。より最近の発展は、下側信頼度を利用するというアイデアである。

獲得関数を構築するための信頼限界 (最大化を考慮する場合の上限)

最適化の過程で後悔を最小化する関数 ([Srinivas et al., 2010](#))。これらの獲得関数は次のような形をとる。

$$(3) \quad a_{\text{LCB}}(x; \{x_n, y_n\}, \theta) = \mu(x; \{x_n, y_n\}, \theta) - \kappa \sigma(x; \{x_n, y_n\}, \theta),$$

調整可能な κ により、活用と探索のバランスをとることができます。

この研究では、期待される改善基準に焦点を当てます。

改善の確率よりも良い振る舞いをするが、GP 上位の方法とは異なり

信頼限界 (GP-UCB) では、独自の調整パラメータを必要としません。

最小化問題で良好なパフォーマンスを発揮する改善が期待されるが、

後悔の形式化は多くの状況においてより適切である。我々は直接比較を行う。

セクション 4.1 では、EI ベースのアプローチと GP-UCB との比較を行います。

3. ハイパーパラメータのベイズ最適化に関する実際的な考慮事項。

高価な関数を最適化するための洗練されたフレームワークではあるものの、機械学習問題におけるハイパーパラメータの最適化手法として広く利用されるには至っていない。第一に、実用的な問題において、共分散関数とそのハイパーパラメータの適切な選択が明確ではない。第二に、関数の評価自体に時間のかかる最適化手順が含まれる場合があり、問題によって実行時間が大きく異なる可能性があることを考慮する必要がある。第三に、最適化アルゴリズムは、現代の計算環境に適切に対応するために、マルチコア並列処理を活用する必要がある。本章では、これらの問題に対する解決策をそれぞれ提案する。

3.1. 共分散関数と共分散超パラメータの扱い。関数上の豊富な分布を表現できるガウス過程の力は、共分散関数にのみ依存している。非退化共分散関数は無限基数に対応するが、それでも尤度の高い関数に関する強い仮定に対応することができる。特に、自動関連性判定 (ARD) の二乗指数カーネルは、

$$(4) \quad KSE(x, x) = \theta_0 \exp - \frac{1}{2r^2} (x, x) \quad {}^{2r} (x, x) = \prod_{d=1}^D (x_d - x_d)^2 / \theta_d^2.$$

ガウス過程回帰では、しばしばデフォルトの選択肢となります。しかし、この共分散関数を持つ標本関数は、実用的な最適化問題においては非現実的なほど滑らかです。そこで、代わりにARD Matérn 5/2カーネルの使用を提案します。

$$(5) \quad KM52(x, x) = \theta_0 \left(1 + 5r^2(x, x) + \frac{5}{2} r^2(x, x) \exp - 5r^2(x, x) \right).$$

この共分散関数は、2 回微分可能なサンプル関数をもたらします。これは、たとえば準ニュートン法によって行われた仮定に対応しますが、2 乗指数の滑らかさを必要としません。

共分散の形式を選択した後、平均関数の挙動だけでなく、共分散の挙動を制御するハイパーパラメータも管理する必要があります (これらの「ハイパーパラメータ」は、全体的なベイズ最適化の対象となるハイパーパラメータとは異なることに注意してください)。

我々が関心のある問題では、典型的には $D + 3$ 個のガウス過程ハイパーパラメータ、すなわち D 個の長さスケール $\theta_{1:D}$ 、共分散振幅 θ_0 、観測ノイズ v 、定数平均 m が用いられる。最も一般的に提唱されているアプローチは、ガウス過程における周辺尤度を最適化することで、これらのパラメータの点推定値を用いることである。

$$p(y | \{x_n\}, \theta, v, m) = N(y | m_1, \Sigma \theta + v),$$

共分散行列である。 $\{y_n\}^T$ であり、 $\Sigma \theta$ はハイパーパラメータ θ のもとで $y = [y_1, y_2, \dots]$ となる N 個の入力点から得られる

しかし、ハイパーパラメータの完全なベイズ処理 (ここでは θ のみで要約) では、ハイパーパラメータを周辺化して統合獲得関数を計算することが望ましい。

$$(6) \quad a^*(x; \{x_n, y_n\}) = a(x; \{x_n, y_n\}, \theta) p(\theta | \{x_n, y_n\}) d\theta,$$




図1:統合された期待改善の図解。(a) 3つの事後サンプルが示されており、それぞれ同じ5回の観測後、異なる長さスケールで得られた結果。(b) 同じデータとハイパーパラメータを用いた、期待される改善獲得関数の3つ。それぞれの最大値が示されている。

(c) 統合された期待改善とその最大値が表示されます。

図2:評価保留中の買収の図解。(a) 3つのデータが観察されている。3つの事後関数が表示され、3つの保留中の評価のための「ファンタジー」が表示されます。(b) 期待される改善は、それぞれの共同空想を条件としており、今後の結果についても同様である。(c) 空想結果を統合した後に期待される改善。

ここで、 $a(x)$ は θ とすべての観測値に依存する。改善の確率と期待される改善、この期待は不確実性を考慮した正しい一般化であるハイパーパラメータで。したがって、サンプルから得られる獲得関数をブレンドすることができる。GPハイパーパラメータの事後分布とモンテカルロ推定による統合分布の推定値を得る。期待される改善。これらのサンプルはスライスサンプリングによって効率的に取得できる。[MurrayとAdams \(2010\)](#)で説明されている。最適化とマルコフ連鎖モンテカルロ法はどちらも計算的にはN次元線形システムを解く立方コストによって支配される

(そして関数の評価はいずれにしてもはるかに高価であると仮定されている)完全なベイズ的处理は合理的であり、我々の経験的評価はそれを裏付けている。図1は統合された期待される改善が獲得機能をどのように変化させるか。

3.2. モデリングコスト。ベイズ最適化の最終的な目的は、良いハイパーパラメータをできるだけ早く設定する。貪欲な獲得手順、例えば期待される改善は、次の機能評価で可能な限り最善の進歩を遂げるように努めます。しかし、実際の観点からは、関数の評価はそれほど重要ではなく、壁時計時間で計算されます。パラメータ空間の領域によって結果が大きく異なる場合があります。実行時間は、正規化や学習率などによって変化するため、パフォーマンスを向上させるために

真の目的関数 $f(x)$ が分からないのと同様に、持続関数 $c(x): X \rightarrow R+$ も分かりません。それでも、ガウス過程の仕組みを用いて、 $f(x)$ と並行して $\ln c(x)$ をモデル化することができます。本研究では、これらの関数は互いに独立していると仮定しますが、それらの結合は、マルチタスク学習の GP バリエント (例: [Teh et al. \(2005\)](#); [Bonilla et al. \(2008\)](#))を用いることで有効に捉えることができます。独立性の仮定の下では、予測される期待逆持続時間を容易に計算でき、それを用いて x の関数として1秒あたりの期待改善率を計算することができます。

明らかに、同じ獲得関数を再び使用することはできません。そうしないと、保留中の実験のいずれかを繰り返すことになります。理想的には、獲得ポリシーのロールアウトを実行し、情報獲得と活用とのバランスが適切に取れるポイントを選択します。しかし、このようなロールアウトは一般的に困難です。そこで、我々は、ガウス過程の扱いやすい推論特性を活用し、保留中の関数評価から得られるさまざまな結果の可能性に基づいて、獲得関数のモンテカルロ推定値を計算する逐次的な戦略を提案します。

$$(7) \hat{a}(x; \{x_n, y_n\}, \theta, \{x_j\}) = \int \prod_{j=1}^J a(x; \{x_n, y\}, \theta, \{x_j, y_j\}) p(\{y_j\} | \{x_j\}) \prod_{j=1}^J \int_{\mathcal{Y}_j} \{x_n, y_n\}_{n=1}^{N_j} dy_1 \cdots dy_J.$$

4. 実証分析。本節では、本論文で紹介するアルゴリズムを実証的に分析し、既存の戦略および人間のパフォーマンスと、いくつかの難解な機械学習問題におけるパフォーマンスを比較する。GP ハイパーパラメータを周辺化しながら期待される改善を「GP EI MCMC」、ハイパーパラメータを最適化する手法を「GP EI Opt」、1秒あたりのEIを「GP EI per Second」、そしてN倍並列化されたGP EI MCMCを「N_x GP EI MCMC」と呼ぶ。

1 すべての実験は、Amazon EC2 サービスを使用して同一のマシンで実施されました。




図3: 標準的なアプローチとGP EI MCMCアプローチの比較

Branin-Hoo関数 (3a)とMNISTデータでのロジスティック回帰のトレーニング (3b)。

4.1. ブランニン・フーとロジスティック回帰。まず、標準的なアプローチと比較し、

2つの標準的な問題に対して、Bergstraら(2011)による最近のTree Parzen Algorithm2 (TPA)を適用した。Branin-Hoo関数は、ベイズ最適化手法の一般的なベンチマークであり(Jones, 2001)、 $x \in \mathbb{R}$ 上で定義される。

² ここで $0 \leq x_1 \leq 15$ かつ $-5 \leq x_2 \leq 15$ である。

また、人気のMNISTのロジスティック回帰分類タスクでTPAと比較します。

データ。アルゴリズムでは、4つのハイパーパラメータ、確率的勾配降下法の学習率（0から1の対数スケール）、2番目の正則化パラメータ（0から10）を選択する必要があります。

1、ミニバッチサイズは20から2000、学習エポック数は5から

2000年。各アルゴリズムはBranin-Hoo問題とロジスティック回帰問題100と10で実行された。

それぞれ時間経過し、平均値と標準誤差が報告されている。これらの分析の結果は

図3aと3bには、関数が評価される回数の観点から示されています。

Branin-Hooでは、ハイパーパラメータの積分は点推定を使用するよりも優れており、

GP EIはTPAを大幅に上回り、最小値を見つける回数は半分以下です。

どちらの場合も評価です。

4.2. オンラインLDA。潜在ディリクレ分布 (LDA)は、多項式「トピック」分布の混合から単語が生成される文書を対象とした有向グラフィカルモデルです。

変分ベイズは学習のための人気のパラダイムであり、最近ではHoffmanら (2010)が

この文脈においてオンライン学習アプローチが提案された。オンラインLDAは、変分法を更新するために用いられる学習率 $\rho_t = (\tau_0 + t) - \kappa$ を制御する2つの学習パラメータ τ_0 と κ を必要とする。

t に基づくLDAのパラメータ ² 文書の単語数ベクトルのミニバッチ。

ミニバッチもまた、選択しなければならない3番目のパラメータである。Hoffman et al. (2010)は、

サイズ $6 \times 6 \times 8$ の網羅的なグリッド検索で、合計 288 個のハイパーパラメータ構成が得られます。

実験にはHoffman et al. (2010)が公開したコードを使用した。

Wikipediaの記事のコレクションにオンラインLDAを適用しました。ランダムに249,560件の

記事は、それぞれ20万語、2万4560語、2万5000語の学習セット、検証セット、テストセットに分割されています。文書は、7702語の語彙の単語数のベクトルとして表現されています。

Hoffman et al. (2010)で報告されているように、検証セット文書の単語あたりのパープリックス度の下限値を性能評価尺度として使用しました。

トピックの数と、トピック上の対称ディリクレ事前分布のハイパーパラメータ η

² <https://github.com/jaberg/hyperopt/wiki> から公開されているコードを使用する




図 4: オンライン LDA 問題におけるさまざまな最適化戦略を、関数評価(4a)、ウォールタイム(4b)、グリッド制約の有無(4c)の観点から比較しました。

文書ごとのトピック混合重みに対する対称ディリクレ事前分布と α Hoffmanら (2010)の分析を模倣するために、実験では100トピック、 $\eta = \alpha = 0.01$ を使用し、論文3で報告されているグリッドサーチを正確に繰り返した。各オンライン LDA評価は通常、収束に5~10時間かかり、グリッドサーチの完了には約60~120プロセッサ日を要する。

図4aと4bでは、この高コストな問題において、同じグリッド上で様々な最適化戦略を比較しています。つまり、アルゴリズムはグリッドサーチによって評価された正確なパラメータ設定のみに制限されています。各最適化は100回繰り返され(毎回、最適化の初期値として2つの異なるランダム実験が選択されます)、平均と標準誤差が報告されています。図4aと4bはそれぞれ、各戦略によって達成された平均最小損失(パープレキシティ)を、新しいパラメータ設定でオンラインLDAが評価された回数と、最適化の期間(日数)と比較して示しています。

図4cは、同じグリッドに制限された3回および5回の並列化GP EI MCMCの平均損失を、同じアルゴリズムの1回の実行と比較したものです。この実行では、アルゴリズムは期待される改善を最適化することにより、同じ範囲内で新しいパラメータ設定を柔軟に選択できます。

この場合、ハイパーパラメータを積分する方が点推定よりも優れています。

³つまり、唯一の違いは、データセット内の記事のランダムなサンプルの収集と、語彙。各評価は10時間、または収束するまで実行しました。

GP EI MCMCは関数評価の点で最も効率的であり、並列化されたGP EI MCMCは、大幅に短い時間で最適なパラメータを見つけます。最後に、図4cでは、並列化されたGP EI MCMCアルゴリズムは、有意に優れた最小値を見つけることがわかる。ホフマンら (2010)がグリッドサーチで使用した結果よりも、実験の数。




図5: M3Eモデルのハイパーパラメータを最適化するための様々な戦略の比較
タンパク質モチーフ探索課題における壁時計時間 (5a)、機能評価 (5b)
および異なる共分散関数(5c)。

4.3. 構造化サポートベクターマシンによるモチーフ発見。この例では、最大マージン最小エントロピー (M3E)モデルの学習パラメータの最適化 (ミラーら、2012年)、これには潜在的構造化サポートベクターマシン (YuとJoachims、2009)が含まれる。特殊なケース。潜在構造SVMは、明示的に問題依存の隠れ変数をモデル化する。よく使われる例としては、二値分類がある。タンパク質DNA配列の解析 (Miller et al., 2012; Yu and Joachims, 2009; Kumar et al., 2010)。モデル化される隠れた変数は、特定の部分列の未知の位置、またはモチーフは、陽性配列の指標です。

構造化SVMの正則化項Cなどのハイパーパラメータの設定は依然として課題であり、通常は時間のかかるグリッドサーチ手順を通じて設定される。

ミラーら (2012)やユウ・ヨアヒムズ (2009)で行われたのと同様である。実際、クマールら (2010)はモチーフ探索タスクでは、ハイパーパラメータの選択は、計算コストが高すぎる。しかし、ミラーら (2012)は、分類が

結果は、タンパク質ごとに異なるパラメータの設定に大きく依存します。

M3Eモデルは、 α でパラメータ化されたエントロピー項を導入し、これにより潜在構造化SVMを大幅に上回る性能を実現します。しかしながら、この性能向上は、問題依存のハイパーパラメータを犠牲にしています。Millerら(2012)の実験を、約40,000個の配列を持つ1つのタンパク質について再現します。パラメータCについては、10⁻¹から10⁶の対数スケールで25通りの設定、 α については0.1から5の対数スケールで14通りの設定、そしてモデル収束許容誤差 $\in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}$ について検証します。

これらのパラメータの1,400通りの組み合わせに対してグリッド検索を実行し、それぞれを5つのランダムな50-50トレーニングおよびテスト分割で評価しました。

図5aと5bでは、ランダム化グリッドサーチを、グリッド上の同じポイントに制約されたGP EI MCMC、GP EI per Second、およびそれらの3倍並列化バージョンと比較しています。これらのアルゴリズムはすべて、最小検証誤差と実時間、および関数評価の観点から比較しています。各アルゴリズムは100回繰り返され、平均と標準誤差が表示されています。ベイズ最適化戦略は、現状のグリッドサーチよりもかなり効率的であることがわかります。この場合、関数評価の点ではGP EI MCMCがGP EI per Secondよりも優れていますが、GP EI per Secondは、他のパラメータを探索しながら早い段階でそれほど厳しくない収束許容値を使用することを学習するため、GP EI MCMCよりも速く、より適切なパラメータを見つけます。

実際、1秒あたり3倍のGP EIは関数評価の点では最も効率が悪いですが、他のすべてのアルゴリズムよりも速く、より優れたパラメータを見つけます。

図5cは、この問題におけるGP EI MCMC最適化における様々な共分散関数の使用を比較したものです。各共分散について最適化を100回繰り返し、平均と標準誤差を示しています。適切な共分散の選択が性能に大きな影響を与え、長さスケールパラメータの推定が重要であることは明らかです。

一般的に使用される二乗指数関数によって課される基礎関数の無限微分可能性の仮定は、この問題には厳しすぎます。




図 6: さまざまな最適化戦略における CIFAR-10 データの検証エラー。

4.4. CIFAR-10における畳み込みネットワーク。ニューラルネットワークや深層学習手法は、多数のハイパーパラメータを慎重に調整する必要があることで知られています。多層畳み込みニューラルネットワークは、Saxeら(2011)で実証されているように、アーキテクチャとハイパーパラメータの徹底的な探索が有益であるものの、多くの場合計算量的に法外な負担となるモデルの一例です。Saxeら(2011)はモデルアーキテクチャを効率的に探索する方法論を示していますが、正則化などの多数のハイパーパラメータは、

残りのパラメータは、Krizhevsky (2009)で説明されている 3 層畳み込みネットワークの 9 つのハイパーパラメータです。この経験的分析では、提供されているコード4 を使用して、CIFAR-10 ベンチマーク データセットで Krizhevsky (2009) に説明されている 3 層畳み込みネットワークの 9 つのハイパーパラメータを調整します。このモデルは、人間の専門家 (Krizhevsky, 2009)によって慎重に調整され、18% のテスト エラーという非常に競争力のある結果を達成しました。これは、CIFAR-10 で公開されている最先端技術5 の結果(Coates and Ng, 2011)と一致します。調査するパラメータには、モデルを実行するエポック数、学習率、4 つの重みコスト (各層に 1 つとソフトマックス出力の重み)、ネットワークのプーリング層における応答正規化の幅、スケール、およびパワーが含まれます。

各戦略について、検証セットを保留し、9つのパラメータを最適化しました。ランダムに初期化された5回の実行における平均検証誤差と標準誤差を報告します。結果は図6に示し、専門家が発見した最良のパラメータを用いた平均結果と比較しています。GP EI MCMCアプローチによって発見された最良のハイパーパラメータ6は、テストセットで14.98%の誤差を達成しました。これは、専門家およびCIFAR-10における最先端技術よりも3%以上優れています。

5. 結論。本論文では、一般的な機械学習アルゴリズムに関連するハイパーパラメータのベイズ最適化手法を紹介した。期待される改善のための完全なベイズ的处理、および可変時間領域と並列実験に対処するアルゴリズムを導入した。実証分析は、機械学習の様々な分野にまたがる、最近発表された3つの難問に対し、本手法の有効性を実証した。使用したコードは公開される。結果として得られたベイズ最適化は、著者が用いた手法よりもはるかに高速に、より優れたハイパーパラメータを発見する。実際、本アルゴリズムは競合するCIFAR-10データセットにおいて、ハイパーパラメータ選択において人間の専門家を凌駕し、結果として最先端技術を3%以上上回った。

謝辞。本研究はAmazon Web Servicesおよび DARPA Young Faculty Award を受賞。

参考文献。

J Mockus, V Tiesis, A Zilinskas. ベイズ法を用いた極値探索への応用。

グローバル最適化, 2:117–129, 1978。

DRジョーンズ. 応答曲面に基づくグローバル最適化手法の分類. グローバル最適化ジャーナル, 21(4):345–383, 2001.

ニランジャン・スリニヴァス、アンドレアス・クラウス、シャム・カカデ、マティアス・シーガー。ガウス過程最適化におけるバンディット設定 : 後悔なしと実験デザイン。JMLR, 2010年。

Adam D. Bull. 効率的なグローバル最適化アルゴリズムの収束率. JMLR, (3-4):2879–2904, 2011.

James S. Bergstra, R'emi Bardenet, Yoshua Bengio, B'azs K'egl. ハイパーパラメータ最適化アルゴリズム. NIPS, 2011.

Eric Brochu, Vlad M. Cora, Nando de Freitas. 高コスト関数のベイズ最適化に関するチュートリアル。アクティブユーザーモデリングと階層的強化学習への応用。プレプリント, 2010年。arXiv:1012.2599。

Carl E. Rasmussen, Christopher Williams 著『機械学習のためのガウス過程』MIT Press, 2006年。

HJクシュナー. ノイズの存在下で任意の多ピーク曲線の最大点を特定する新しい方法. Journal of Basic Engineering, 86, 1964.

4 入手先: <http://code.google.com/p/cuda-convnet/> [http://codeで定義されたアーキテクチャを使用します。](http://code.google.com/p/cuda-convnet/source/browse/trunk/example-layers/layers-18pct.cfg)
[google.com/p/cuda-convnet/source/browse/trunk/example-layers/layers-18pct.cfg](http://code.google.com/p/cuda-convnet/source/browse/trunk/example-layers/layers-18pct.cfg) 5 トレーニングデータを拡張しない場合。

6 最適化されたパラメータは、専門家が決定した設定から興味深いほどに逸脱しています。たとえば、最適な重みコストは非対称です (第 2 層の重みコストは第 1 層よりも約 1 桁小さくなります)、学習率は 2 桁小さくなり、応答の正規化はわずかに広くなり、スケールは大きくなり、パワーははるかに小さくなります。

Iain MurrayとRyan Prescott Adams。潜在ガウスモデルのスライスサンプリング共分散ハイパーパラメータ。
NIPS.1723-1731ページ。2010年。

Yee Why Teh,Matthias Seeger,Michael I. Jordan。セミパラメトリック潜在因子モデル。AISTATSでは、
2005年。

Edwin V. Bonilla,Kian Ming A. Chai,Christopher KI Williams. マルチタスクガウス過程予測。
NIPS.2008年。

David GinsbourgerとRodolphe Le Riche. 並列ガウス過程に基づくグローバル最適化における非同期性の扱い。2010.

マシュー・ホフマン、デイヴィッド・M・ブレイ、フランシス・バッハ。潜在ディリクレ配分のためのオンライン学習。NIPSでは、
2010年。

ケビン・ミラー、M・パワン・クマール、ベンジャミン・パッカー、ダニー・グッドマン、ダフネ・コラー。最大マージン最小
エントロピーモデル。AISTATS.2012年。

Chun-Nam John YuとThorsten Joachims. 潜在変数を用いた構造SVMの学習。ICML, 2009.

M. パワン・クマール、ベンジャミン・パッカー、ダフネ・コラー。潜在変数モデルのための自己ペース学習。
生理学研究所。2010.

アンドリュー・サックス、バン・ウェイ・コー、ジェンハオ・チェン、マニーシュ・バンド、ビビン・スレッシュ、アンドリュー・ン。ランダムに
重みと教師なし特徴学習。ICML.2011年。

アレックス・クリジェフスキー「小さな画像から多層的な特徴を学習する」。トロント大学コンピュータサイエンス学部技術報告書、2009年。

Adam CoatesとAndrew Y. Ng. 「深層ネットワークにおける受容野の選択」NIPS.2011年。

ジャスパー・スノエク トロ
ント大学コンピュータサイエンス学部 Eメール:
jasper@cs.toronto.edu

Hugo Larochelle シャーブルック
大学 コンピュータサイエンス学部 メールアドレス:
hugo.larochelle@usherbrooke.ca

ライアン・P・アダムス ハーバ
ード大学工学応用科学部 Eメール: rpa@seas.harvard.edu